

Tema 7: Shell Avanzado, Filtros y Expresiones Regulares

Este tema cubre las herramientas de filtrado de texto de Unix, que son extremadamente potentes. Te permiten procesar ficheros de texto de forma eficiente usando la filosofía Unix: cada herramienta hace una cosa bien, y se combinan con pipes.

Expresiones regulares

Las expresiones regulares son patrones para buscar texto. Los metacaracteres básicos son: el punto, que coincide con cualquier carácter; el asterisco, que significa cero o más repeticiones del carácter anterior; el acento circunflejo, que significa inicio de línea; y el signo dolar, que significa fin de línea. Los corchetes definen clases de caracteres: `a, e, i, o, u` coincide con cualquier vocal. El guion dentro de los corchetes define rangos: `0-9` coincide con cualquier dígito. El acento circunflejo dentro de los corchetes niega: `[^0-9]` coincide con cualquier cosa que no sea un dígito.

En expresiones regulares extendidas, que se usan con `egrep`, tenemos además: el `+`, que significa una o más repeticiones; la interrogación, que significa cero o una repetición; la barra vertical, que es alternativa o OR; y los parentesis para agrupar. Las llaves con un número indican repeticiones exactas.

grep y egrep

`Grep` busca patrones en ficheros o en la entrada estándar. La sintaxis es `grep patron fichero`. Las opciones principales son: `-i` para ignorar mayúsculas, `-v` para invertir la búsqueda mostrando las líneas que no coinciden, `-c` para contar coincidencias, y `-n` para mostrar números de línea.

`Egrep` es `grep` con expresiones regulares extendidas. Es equivalente a `grep -E`. Permite usar el `+`, la interrogación, la barra vertical y los parentesis sin necesidad de escaparlos.

Ejemplo de uso: para buscar todas las líneas que contienen exactamente tres dígitos, usas `egrep '[0-9]{3}' fichero`.

sed: el editor de flujo

`Sed` procesa texto línea por línea aplicando transformaciones. El uso más común es la sustitución: `sed 's/barra viejo/barra nuevo/g' fichero`. La `s` indica sustitución, las barras separan el patrón de búsqueda, el reemplazo, y la `g` al final significa global, es decir, que cambia todas las ocurrencias en cada línea, no solo la primera.

Otros usos de `sed`: borrar líneas que coincidan con un patrón con `sed 's/patron/d'`. Borrar un rango de líneas por número: `sed '2,5d'` borra las líneas de la dos a la cinco. Imprimir solo ciertas líneas con la opción `-n` y el comando `p`.

`Sed` es muy potente para transformar texto automáticamente. En tus scripts lo usarás frecuentemente para normalizar nombres de fichero, cambiar extensiones, eliminar espacios extra, y cosas similares.

awk: procesamiento de campos

Awk es un lenguaje de programación para procesar texto campo por campo. Por defecto, divide cada línea en campos separados por espacios. El primer campo es dolar uno, el segundo dolar dos, y así sucesivamente. Dolar cero es la línea completa. La variable NF contiene el número de campos, y NR el número de línea.

La sintaxis básica es `awk de comilla llaves print dolar uno llaves comilla fichero`, que imprime el primer campo de cada línea. Puedes especificar un separador distinto con la opción `FS`. Por ejemplo, `awk FS="." de comilla llaves print dolar tres llaves comilla` es útil para procesar el fichero `passwd`, donde los campos están separados por dos puntos.

Awk también permite condicionales: `awk de comilla dolar tres mayor que mil llaves print dolar uno llaves comilla` imprime el primer campo de las líneas cuyo tercer campo sea mayor que mil.

sort: ordenar

Sort ordena líneas de texto. Las opciones principales son: `menos n` para ordenar numericamente en vez de lexicográficamente, `menos r` para orden inverso, `menos k` para especificar la columna de ordenación, y `menos t` para especificar el separador de campos. Por ejemplo, `sort menos n menos k 2` ordena por la segunda columna numericamente.

`Menos u` elimina duplicados al ordenar, y `menos o` permite escribir la salida al mismo fichero de entrada de forma segura.

uniq: eliminar duplicados

Uniq elimina líneas duplicadas consecutivas. Es importante: las líneas deben estar ordenadas para que uniq funcione, por eso casi siempre se usa después de sort. Las opciones principales son: `menos c` para contar cuantas veces aparece cada línea, y `menos d` para mostrar solo las duplicadas.

Un patrón muy común es: `sort fichero barra vertical uniq menos c barra vertical sort menos rn`, que ordena, cuenta duplicados y muestra los más frecuentes primero.

find: buscar ficheros

Find busca ficheros en el sistema de ficheros. La sintaxis es `find directorio opciones`. Los filtros principales son: `menos name` para buscar por nombre con comodines, `menos type f` para buscar solo ficheros regulares, `menos type d` para solo directorios. Se pueden combinar filtros con `menos o` para OR y con parentesis.

Ejemplo: `find punto menos type f menos name asterisco punto c menos print` busca todos los ficheros punto c recursivamente desde el directorio actual.

`Menos print0` imprime los nombres terminados en `null` en vez de nueva línea, lo que es más seguro para ficheros con espacios en el nombre. Se usa con `xargs menos 0`.

du: espacio en disco

Du muestra el espacio que ocupa un directorio. Las opciones principales son: menos s para mostrar solo el total, menos h para formato legible con kilobytes y megabytes, y menos k para mostrar en kilobytes.

head y tail: principio y final

Head muestra las primeras lineas de un fichero. Tail muestra las ultimas. La opcion menos n especifica cuantas lineas. Tail menos f sigue mostrando nuevas lineas a medida que se anaden al fichero, util para monitorizar logs.

cut y paste: extraer y pegar columnas

Cut extrae campos o caracteres de cada linea. Las opciones son: menos f para especificar campos, menos d para el delimitador, y menos c para caracteres por posicion. Paste hace lo contrario: une lineas de varios ficheros lado a lado.

tr: traducir caracteres

Tr reemplaza o elimina caracteres. La sintaxis es tr conjunto1 conjunto2, donde cada caracter del conjunto uno se reemplaza por el correspondiente del conjunto dos. La opcion menos d elimina caracteres. Ejemplos utiles: tr A-Z a-z convierte a minusculas, tr menos d cero-nueve elimina todos los digitos, y tr espacio guion bajo convierte espacios en guiones bajos.

xargs: construir comandos

Xargs lee datos de la entrada estandar y los pasa como argumentos a un comando. Es util para combinar find con otros comandos. El patron mas comun es: find punto menos name asterisco punto o barra vertical xargs rm menos f, que busca y borra todos los ficheros punto o.

La opcion menos cero junto con find menos print0 maneja correctamente ficheros con espacios o caracteres especiales en el nombre.

join: union relacional

Join hace un inner join entre dos ficheros ordenados por una columna clave. Los dos ficheros deben estar ordenados por la columna de union. La opcion menos uno N especifica la columna clave del primer fichero, y menos dos N la del segundo.

Redirecciones y pipes

En el shell, mayor que redirige la salida estandar a un fichero truncandolo. Doble mayor que anade al final sin truncar. Dos mayor que redirige la salida de error. Dos mayor que

ampersand uno redirige la salida de error a la salida estandar. Menor que toma la entrada desde un fichero.

La barra vertical conecta la salida de un comando con la entrada del siguiente. Se pueden encadenar multiples pipes: comando uno barra vertical comando dos barra vertical comando tres.

Estos son los bloques basicos para construir scripts potentes. La filosofia Unix es combinar herramientas simples con pipes para resolver problemas complejos.